Atelier 2

TEI

Sommaire

1 Introduction à la notion de schéma **2**

2 TEI : Définition et objectifs **3**

3 Histoire et ambition de la TEI **3**
- 3.1 Naissance en 1987 . . . 3
- 3.2 Mise en œuvre . . . 3
- 3.3 Institutionnalisation (1999-2000) . . . 4

4 Les grands points forts **4**

5 Organisation du Consortium **5**

6 Un projet Open-Source et collaboratif **5**

7 Entrepôts GitHub **5**

8 TEI n'est pas un schéma **5**

9 Un modèle pour de nombreuses applications **6**

10 Aspect modulaire **6**

11 Organisation des guidelines en modules **7**

12 Composition d'un document TEI **7**

13 Observation de la structure minimale du document **7**

14 Cas particulier des teiCorpus **8**

15 Revenons sur notre document TEI : le header minimal **9**

16 Alors tient compte des différents niveaux d'abstraction de l'objet texte **9**

17 Point sur les conventions de nommage des éléments TEI **9**

18 Le header peut être très très riche **9**
- 18.1 Élements courants . . . 9
- 18.2 Modules du header . . . 10

19 Le texte : structure et les balises les plus courantes **10**
19.1 Contenu direct de l'élément <text> . . . 10
19.2 Structuration générique . . . 10
19.3 Structuration de la prose . . . 10
19.4 Structures versifiées et théâtre . . . 10
19.4.1 Le paratexte (<front>) . . . 11
19.4.2 Le corps de la pièce (<body>) : . . . 11
19.4.3 Exemple simplifié d'encodage d'une réplique . . . 11
19.5 Structure matérielle . . . 11
19.6 Les références internes . . . 12
19.7 <addSpan> et <anchor> . . . 12
19.8 <persName>, <placeName> et création d'un index . . . 13

20 TEI pour l'édition scientifique **13**
20.1 Focus sur l'édition paléographique . . . 14
20.2 Relier la transcription à la page matérielle . . . 14
20.3 Régularisation des graphies . . . 15
20.4 Utilisation des entités pour les caractères spéciaux . . . 15
20.4.1 Références numériques . . . 16
20.4.2 Entités personnalisées (DTD) . . . 16
20.5 Caractères non standard en TEI . . . 16
20.6 Lacune, ajouts, description des mains . . . 17
20.7 Ajouts et surplus . . . 17
20.8 La description des mains . . . 17

21 Quelques informations sur la Séquence (ou Cantilène) de sainte Eulalie **17**

22 Bibliographie et références **18**

1 Introduction à la notion de schéma

On a vu ce qu'était un document **bien formé**. Un document peut par ailleurs être **valide**, ce n'est pas la même chose. Il s'agit d'un terme technique signifiant que le document n'utilise que certains éléments, et ce, uniquement dans des contextes précis. Par exemple, une entrée de dictionnaire peut comporter une vedette (le mot-clé), une indication de prononciation et une série de définitions, chacune accompagnée d'exemples. Vous pouvez définir des règles qui indiquent dans quel ordre les éléments doivent apparaître, où ils peuvent être placés et lesquels peuvent être répétés. Par exemple, ces règles peuvent permettre d'associer plusieurs définitions à une même vedette, et d'ajouter plusieurs exemples à chacune de ces définitions.

Cet ensemble de règles, ou grammaire du document, est appelé "schéma".

Un document XML **valide** spécifie nécessairement, ou implique, un certain schéma dans lequel ses éléments constitutifs sont définis et où sont indiquées les règles relatives à leur utilisation.

XML propose plusieurs langages de schémas capables de formaliser une telle grammaire. Un document

XML “bien formé” peut ainsi être en plus **valide sur schéma** pour vérifier la cohérence de l’édition.

Tous les documents doivent être bien formés, mais la validité dépend des objectifs du projet d’encodage et aussi de son avancement. Souvent, le schéma, les règles de validation, se dessinent au cours de l’encodage.

2 TEI : Définition et objectifs

> Offre un schéma (ndlr : plutôt un méta-schéma) commun pour que des textes électroniques produits par des équipes différentes, dans des disciplines différentes, puissent être échangés, comparés et réutilisés. Pour qu’un texte produit par un chercheur particulier puisse valoir pour une communauté plus large et sur le long terme.

Pour cela TEI met à disposition un set de balises prédéfini et documenté dans les TEI guidelines qui permet de procéder à une description “scientifique” et “sémantique” d’un texte.

> Même si elle s’incarne dans cet ensemble de balises, elle est aussi conçue comme un ensemble de principes abstraits, indépendants des technologies.

C’est donc avant tout un cadre pour penser la nature du texte : elle constitue une sorte d’encyclopédie de notions textuelles associées à des balises et des règles sur la façon dont elles peuvent être combinées.

3 Histoire et ambition de la TEI

3.1 Naissance en 1987

La TEI naît d’un constat partagé par les Humanités numériques naissantes : à la fin des années 80 chaque projet d’édition de textes utilisait son propre balisage, ce qui rendait les corpus ainsi constitués incompatibles entre eux et mettait donc en danger la pérennité des données.

La TEI naît d’un effort pour créer des ressources textuelles partageables.

Une réunion se tient en novembre 1987 au Vassar College, organisée sous l’égide de l’*Association for Computers in the Humanities* et financée par le *National Endowment for the Humanities* ; elle rassemble un groupe pluridisciplinaire de chercheurs représentant des sociétés savantes, des bibliothèques, des archives et des projets d’Europe, d’Amérique du Nord et d’Asie. C’est à cette occasion qu’est formulé le fondement intellectuel de la *Text Encoding Initiative*.

Le projet est porté conjointement par trois sociétés savantes de référence : l’*Association for Computers and the Humanities*, l’*Association for Computational Linguistics* et l’*Association for Literary and Linguistic Computing*.

3.2 Mise en œuvre

Le projet démarre en 1988 avec la formation de quatre groupes de travail :

- ✻ questions de documentation textuelle
- ✻ de représentation du texte
- ✻ d'analyse et d'interprétation
- ✻ de métalangage et de syntaxe

…Qui décident de l'adoption de SGML comme langage de balisage.

…Qui produisent la première version complète, avec publication des *Guidelines for the Encoding and Interchange of Machine-Readable Texts*, un document qui fournit des conventions d'encodage pour une large gamme de types de textes et de traits pertinents pour la recherche en linguistique, en humanités et en traitement automatique des langues.

3.3 Institutionnalisation (1999-2000)

Après 10 ans d'existence en tant que projet de recherche, la TEI se dote d'une structure pérenne, en 1999, l'Université de Virginie et l'Université de Bergen proposent formellement la création d'une organisation internationale, le TEI Consortium, chargée de maintenir, développer et promouvoir la TEI. Peu après, deux autres institutions historiquement liées à la TEI, Brown University et Oxford University, les rejoignent pour formaliser un accord de création du consortium.

DONC TEI désigne deux choses : - des recommandations pour encoder les textes, ce qui définit un format pour l'interopérabilité des ressources textuelles - une communauté de recherche qui maintient le standard vivant.

L'évolution la plus significative pendant cette période est le passage du SGML au XML dans les années 2000. C'est la preuve que TEi est conçue comme un modèle qui surplombe les technologies dans laquelle elle s'incarne. C'est avant tout une description théorique et formelle de ce qu'est un texte pour les chercheurs et chercheuses.

4 Les grands points forts

- ✻ Rencontre des communautés : encodage centré sur plusieurs niveaux de **contenus intellectuels** :
  - ✻ *Visuel* : Aspect physique (codicologie, manques, foliation, etc.) et aspects paléographiques (abréviations et formes développées, etc.)
  - ✻ *Sémantique* : Toponymes, anthroponymes, dates, balisage des types de discours, désambiguïsation des références textuelles…
  - ✻ *Analytique* : Correspondance des parties du texte à une grille d'analyse (taxonomie, thésaurus, etc.)
- ✻ **Conçue par et pour les chercheurs et chercheuses** : L'objectif est d'aider les chercheurs et chercheuses à créer des ressources textuelles adaptées aux besoins de la recherche
- ✻ **Interopérabilité et pérennité** : Indépendant de tout environnement logiciel et de toute technologie, permet l'échange et la collaboration

5 Organisation du Consortium

- Le TEI Council : Formé de 12 personnes, chargé de l'élaboration et évolution des Guidelines.
- Le TEI Board of Directors : Chargé de la gestion du Consortium (orientations stratégiques, gestion financière, recrutement, etc.).
- Une large communauté d'utilisateurs :
  - Workgroups
  - SIG Special Interest Groups
  - Liste de diffusion tei-l
  - Liste de diffusion francophone tei-fr

6 Un projet Open-Source et collaboratif

- Le code source de la TEI est distribué de manière libre et open source par l'intermédiaire d'un entrepôt GitHub auquel vous pouvez contribuer.
- Un projet collaboratif : discussion des problèmes rencontrés, suggestions de modifications sur les listes et le gestionnaire de bugs

7 Entrepôts GitHub

- Le consortium TEI sur GitHub
- Entrepôt des Guidelines
- Gestionnaires d'issues des Guidelines

8 TEI n'est pas un schéma

La TEI, dans sa forme complète qu'on appelle "TEI All" n'est pas vraiment un schéma, car il est trop large. Un document peut être validé sur TEI all, c'est vrai, mais ça ne veut pas dire grand-chose. C'est plutôt un framework, c'est-à-dire un très vaste ensemble de règles, d'éléments, d'attributs et de modules, conçu pour qu'on puisse en extraire un schéma adapté à son propre projet.

La TEI complète couvre des besoins extrêmement variés : encoder de la poésie médiévale, des dictionnaires, des éditions génétiques de manuscrits, des correspondances, du théâtre… Donc valider sur TEI All ce n'est pas assez stricte, ça revient à autoriser tout et n'importe quoi. Donc, on perd l'intérêt principal de la validation qui est d'assurer la cohérence d'un travail d'encodage, en vérifiant qu'il respecte des contraintes précises et adaptées au corpus.

Alors, si la TEI n'est pas un schéma en soi, comment est-ce qu'on l'utilise concrètement ? C'est là qu'intervient la distinction entre modèle abstrait et implémentation.

9 Un modèle pour de nombreuses applications

On peut distinguer deux niveaux dans la TEI.

Le premier niveau, c'est le modèle abstrait ou conceptuel. C'est l'ensemble des concepts que propose la TEI. Par exemple la notion de "personne", de "lieu", de "note", d' "acte", de "paragraphe", avec les relations logiques entre ces concepts : est-ce qu'une note peut contenir un nom de personne ? Est-ce qu'une référence biblio peut avoir une date ? Ce niveau se voudrait indépendant de toute technologie particulière : c'est de la modélisation intellectuelle, de la réflexion sur la structure de l'information, sur le papier elle se veut indépendante du XML, mais en réalité on constate qu'on pense une structure hiérarchique, donc il y a quand même un modèle logique derrière qui inclut dès le départ le modèle formel ou computationnel.

Le second niveau, c'est l'implémentation. C'est le moment où on traduit ce modèle intellectuel en contraintes formelles, concrètement au moyen d'un schéma de validation. C'est ce schéma, propre à votre projet, qui va dire : dans ce corpus, un élément `<persName>` doit obligatoirement avoir un attribut `@ref`, ou bien tel élément ne peut apparaître qu'à l'intérieur de tel autre.

10 Aspect modulaire

Ce grand ensemble de règle est rassemblé dans les *Guidelines*, qui à partir de maintenant deviennent votre bible.

Les Guidelines de la TEI définissent plusieurs centaines de concepts différents, avec les instructions détaillées sur les éléments qui peuvent être utilisés pour les représenter. La plupart des documents TEI n'a besoin que d'une petite partie de ce qui est fourni.

Les projets d'encodage utilisent bien souvent un sous-ensemble très restreint de la TEI : un schema sur mesure adapté aux spécificités de ce qu'on encode et aux questions de recherche, et il y a des outils pour aider à la création de tels schémas, on verra notamment Roma. Il faut préciser ici que non seulement on s'adapte au type de document qu'on encode, mais aussi à ce qu'on cherche dans le document, donc l'encodage autorise d'être plus ou moins proche du texte. On distingue donc le `close reading` et le `distant reading`.

Le XML des notes Christofle est très proche du texte avec encodage des noms de personnes, résolution des abbréviations, etc. Mais si on prend un autre exemple issu du projet [eBalzac](https://github.com/ebalzac/FC/blob/gh-pages/balzac-11-FC-madame-firmiani.xml, on a plutôt un encodage léger (découpage du texte en chapitres et paragraphe, les notes).

Donc, on travaille dans une logique de réduction, et on peut partir soit de :

- **Tei Lite** = designed to meet 90% of the needs of 90% of the TEI user community

soit de :

- **Tei All** = inventaire complet qui contient plus de 570 éléments et 200 attributs

11 Organisation des guidelines en modules

Donc les guidelines définissent plusieurs centaines d'éléments et d'attributs différents. Elles sont organisées en modules, soit en grands chapitres qui correspondent à des ensembles cohérents de déclarations de balises.

Chaque élément est attribué à un seul module, généralement destiné à une application particulière ou à prendre en charge un type spécifique d'utilisation. Un module constitue donc simplement une manière pratique de regrouper un certain nombre de déclarations d'éléments associées. Dans le cas le plus simple, un schéma TEI est créé en combinant un petit nombre de modules.

- Il y a des modules obligatoires pour renseigner les métadonnées et couvrir les balises les plus courantes.
  - `tei` : définition des classes, macros et types de données
  - `textstructure` : éléments de base pour structurer un texte de type livre
  - `core` : éléments incontournables pour tout type de document
  - `header` : en-tête TEI (métadonnées du document)
- Auquels s'ajoutent les modules additionnels qui correspondent à l'encodage d'un type de texte (poésie, dictionnaires, etc.) ou d'un type de données et d'informations (apparat critique, élément graphique, etc.)

12 Composition d'un document TEI

Tout document TEI commence par une balise racine `<TEI>` et contient *a minima* deux parties :

- un **en-tête** qui contient les métadonnées du document → `<teiHeader>`
- le **texte** → `<text>`

Avant ou après l'élément `<text>`, on peut intégrer les éléments :

- `<facsimile>` : information physique sur le source
- `<standOff>` : annotations et données externes comme les listes / index / analyses linguistiques et textuelles / métadonnées de provenance
- `<sourceDesc>` : transcription brute issue de l'OCR
- `<fsDecl>` : aucune idée de à quoi ça sert

13 Observation de la structure minimale du document

La structure suivante suffit à produire un document TEI valide.

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
 <teiHeader>
    <fileDesc>
        <titleStmt>
```

```
            <title></title>
        </titleStmt>
        <publicationStmt>
            <p></p>
        </publicationStmt>
        <sourceDesc>
            <p></p>
        </sourceDesc>
    </fileDesc>
 </teiHeader>
 <text>
    <body>
        <p></p>
    </body>
 </text>
</TEI>
```

On commence par l'élément racine `<TEI>`, dans la balise on note la déclaration de l'espace de nom TEI pour dire : "toutes les balises ont cette caractéristique" (cf. prochain atelier).

Ensuite les deux gros blocs sont le `<teiHeader>` et le `<text>`. Dans le teiHeader le seul élément obligatoire est le `<fileDesc>`. Le `<fileDesc>` doit contenir un `<titleStmt>` qui lui-même contient le titre (`<title>`) du document numérique.

Même logique pour `<publicationStmt>` et `<sourceDesc>` : le schéma TEI exige qu'ils soient présents et qu'ils contiennent au moins un `<p>`, mais n'impose pas de contenu particulier, d'où les balises vides ici. C'est un point intéressant : un document peut être valide (conforme au schéma) sans être informatif. La validation vérifie une structure, pas une qualité de contenu.

Deuxième grande partie du document : `<text>`, qui contient ici directement `<body>` et après, on peut attaquer le corps du texte.

Dans cette structure nous avons tous les blocs obligatoires, et à cela s'ajoutent tout un tas de blocs optionnels, par exemple le `<fileDesc>` peut avoir des frères et sœurs `<profileDesc>` et `<encodingDesc>`. Le `<body>` peut avoir des frères et sœurs qui s'appellent `<front>` et `<back>`, etc. on va voir ça tout de suite.

14 Cas particulier des teiCorpus

Il y a un cas particulier les `<teiCorpus>` qui rassemblent un ensemble de documents TEI. Ça permet de garder l'individualité de chaque texte, et chaque document TEI a ses propres métadonnées dans son `<teiHeader>`, mais le tout est distribué en un seul fichier qui peut avoir des métadonnées englobantes.

15 Revenons sur notre document TEI : le header minimal

Contient donc trois éléments :

- `<titleStmt>` : information sur le document lui-même
- `<publicationStmt>` : information sur la diffusion du document ou de sa source
- `<sourceDesc>` : informations sur la source

16 Alors tient compte des différents niveaux d'abstraction de l'objet texte

- Document source : document physique qui a été numérisé et sur lequel s'appuie l'encodage
- Document numérisé : Le document image issu de la numérisation du document source
- Document encodé : Le document numérique en lui-même au format XML-TEI

17 Point sur les conventions de nommage des éléments TEI

Le nom de l'élément peut aider à comprendre à quoi ils servent

- `*Stmt` : Contenu structuré en sous-éléments
- `*Desc` : Description en prose, pouvant admettre des sous-éléments
- `*Decl` : Déclarations associant sous-éléments et description en prose

18 Le header peut être très très riche

Le seul élément obligatoire est le `fileDesc` mais il a de nombreux frères et sœurs neveux et nièces.

18.1 Élements courants

- `<profileDesc>` : Description détaillée des aspects non bibliographiques : informations contextuelles (sujet, contexte de production, langue, etc.)
  - `<settingDesc>` : Information sur le contexte, notamment les lieux mentionnés dans le texte
  - `<particDesc>` : Informations sur les personnes citées dans le texte
  - `<creation>` : Information sur la date de création du texte (≠ date de publication)
  - `<langUsage>` : Information sur les langues présentes dans le texte
- `<encodingDesc>` : Description des choix d'encodage
- `<revisionDesc>` : Informations sur les modifications apportées à l'encodage depuis la version initiale
- `<xenoData>`

18.2 Modules du header

Le *header* peut être étendu par différents modules optionnels en fonction de la nature du texte encodé : `msdescription` pour les manuscrits, `textcrit` pour l'édition critique, etc.

19 Le texte : structure et les balises les plus courantes

19.1 Contenu direct de l'élément `<text>`

- `<front>` : pour les préfaces et tous les éléments liminaires du texte
- `<body>` : pour le corps du texte proprement dit
- `<back>` : pour tous les appendices, épilogues, postface, etc.

19.2 Structuration générique

Balise	Utilisation
`<div>`	Division générique (peut inclure des `div`)
`<div1>`	Division de niveau 1
`<div2>`	Division de niveau 2
`<div3>`	Division de niveau 3
`<div4>`	Division de niveau 4
`<div7>`	Division de niveau 7

19.3 Structuration de la prose

Balise	Utilisation
`<p>`	Paragraphe
`<seg>`	Division neutre, par défaut
`<list>`	Liste contenant des `item`
`<quote>`	Citation simple
`<cit>`	Citation avec référence (bibl)
`<table>`	Tableaux
`<figure>`	Images

19.4 Structures versifiées et théâtre

Balise	Description
`<lg>`	Groupe de vers (strophe, quatrain, tercet, etc.)
`<l>`	Vers
`<sp>`	Intervention d'un locuteur (réplique)
`<speaker>`	Nom du locuteur tel qu'il apparaît avant sa réplique
`<stage>`	Indication scénique (didascalie)
`<castList>`	Liste des personnages (distribution)
`<castItem>`	Élément de la liste des personnages
`<div type="act">`	Acte
`<div type="scene">`	Scène

19.4.1 Le paratexte (<front>)

- `<set>` : décrit le décor, le lieu, le temps et l'ordre d'entrée en scène (attention : il ne s'agit pas d'une didascalie courante mais d'un résumé du cadre spatio-temporel).
- `<performance>` : indique les conditions ou l'historique d'une représentation (dans la préface/-postface).
- `<castList>` : la liste des personnages, structurée avec `<castGroup>` et `<castItem>` contenant `<role>`, `<roleDesc>` et éventuellement `<actor>`.

19.4.2 Le corps de la pièce (<body>) :

- Les divisions majeures (`<div type="act">`, `<div type="scene">`)
- didascalies ou indications scéniques (`<stage>`)
  - Les répliques des personnages à l'intérieur d'un élément `<sp>` (pour *speech*)
  - L'attribut `who="..."` sur `<sp>` identifie le locuteur de façon normalisée (relié à l'identifiant @xml:id du rôle dans la distribution)
    - L'élément `<speaker>` qui contient le nom du personnage tel qu'il apparaît avant sa réplique.
    - Le texte de la réplique lui-même, généralement balisé en prose (`<p>`) ou en vers (`<l>` regroupés dans `<lg>`)

19.4.3 Exemple simplifié d'encodage d'une réplique

```
<sp who="#alceste">
  <speaker>ALCESTE</speaker>
  <stage type="delivery">poussant un soupir</stage>
<p>Non, il n'est point de sort plus digne d'envie...</p>
```

19.5 Structure matérielle

Balise	Utilisation
`<pb/>`	Changement de page avec un attribut `@n` pour le numéro de page qui commence
`<cb/>`	Changement de colonne
`<lb/>`	Changement de ligne

Ce sont des éléments de type milestone (balises auto-fermantes), qui désignent un point dans le flux textuel au même titre que `<milestone/>` élément borne permettant de délimiter une partie section de texte sans l'encadrer de manière un peu différente que l'élément `<anchor/>`.

19.6 Les références internes

En TEI, un élément peut en désigner un autre dans le même document grâce à son `xml:id`. La cible porte un `@xml:id` (unique dans le document), et l'élément qui la référence utilise un attribut de pointage (`@spanTo`, `@ref`, `@facs`, `@target`…) dont la valeur commence par `#`.

```
<p>
  Il partit au matin
  <addSpan spanTo="#fin-ajout" place="margin"/>
  et marcha longtemps sur la route
  <anchor xml:id="fin-ajout"/>
  avant d'arriver au village.
</p>
```

19.7 <addSpan> et <anchor>

`<addSpan>` marque le début d'un ajout qui s'étend sur plusieurs éléments ; `@spanTo` pointe vers l'`<anchor>` qui en marque la fin.

Exemples

```
<p>
  Il partit au matin
  <addSpan spanTo="#fin-ajout" place="margin"/>
  et marcha longtemps sur la route
  <anchor xml:id="fin-ajout"/>
  avant d'arriver au village.
</p>
```

Tout ce qui se trouve entre `<addSpan/>` et `<anchor/>` est considéré comme ajouté (ici, dans la marge).

19.8 <persName>, <placeName> et création d'un index

On identifie chaque personne ou lieu dans une liste (`<listPerson>`, `<listPlace>`), avec un `@xml:id`. Dans le texte, `@ref` renvoie à cette entrée.

```
<!-- Dans le teiHeader (ou en fin de document) -->
<listPerson>
  <person xml:id="eulalie">
    <persName>Eulalie</persName>
    <note>Martyre de Barcelone</note>
  </person>
  <person xml:id="maximien">
    <persName>Maximien</persName>
  </person>
</listPerson>

<listPlace>
  <place xml:id="barcelone">
    <placeName>Barcelone</placeName>
  </place>
</listPlace>

<!-- Dans le texte -->
<p>
  <persName ref="#eulalie">Eulalie</persName> vivait à
  <placeName ref="#barcelone">Barcelone</placeName>.
  L'empereur <persName ref="#maximien">Maximien</persName>
  voulut la faire abjurer.
</p>
```

Intérêt : toutes les occurrences d'une même entité sont reliées à une seule fiche. Par transformation XSLT, on peut alors générer automatiquement un **index** (noms de personnes, noms de lieux) listant chaque entité avec les passages où elle apparaît, même si le nom est écrit différemment dans le texte (*Eulalia*, *Eulalie*…).

À retenir : le `#` est obligatoire dans `@ref`, `@spanTo`, `@facs`… car il indique une référence interne au document.

20 TEI pour l'édition scientifique

Différents types d'édition scientifique ont des besoins différents.

20.1 Focus sur l'édition paléographique

Une édition paléographique vise à rendre compte de l'état d'un texte médiéval tel qu'il apparaît dans le manuscrit : graphies d'origine, abréviations, ajouts, ratures, mise en page, découpage en lignes. La TEI permet d'encoder ces phénomènes (`<orig>`, `<abbr>`, `<add>`, `<del>`, `<lb>`) en proposant, si l'on veut, une lecture régularisée (`<reg>`, `<expan>`, `<corr>`) dans le même fichier. On peut aussi relier le texte à l'image du manuscrit grâce à `<facsimile>`. À partir d'une même source, on peut ensuite produire une édition diplomatique et une édition normalisée ou une édition critique.

Documentation de référence : TEI Guidelines, chapitre 11 « Representation of Primary Sources »

20.2 Relier la transcription à la page matérielle

Dans la TEI, l'élément `<facsimile>` décrit l'image source (page numérisée). Chaque ligne du texte peut être liée à une zone précise de l'image grâce à l'attribut `facs`, qui pointe vers l'`xml:id` d'une `<zone>`.

- `<surface>` : une page ou une face numérisée
- `<graphic>` : le fichier image
- `<zone>` : un rectangle de l'image (coordonnées `ulx, uly` = coin haut-gauche, `lrx, lry` = coin bas-droit)
- `<lb facs="#id"/>` : un saut de ligne relié à la zone correspondante

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
  <teiHeader>…</teiHeader>

  <facsimile>
    <surface xml:id="page1">
      <graphic url="manuscrit_p1.jpg" width="2000px" height="3000px"/>
      <zone xml:id="l1" ulx="120" uly="200" lrx="1850" lry="260"/>
      <zone xml:id="l2" ulx="120" uly="270" lrx="1850" lry="330"/>
    </surface>
  </facsimile>

  <text>
    <body>
      <p>
        <pb facs="#page1"/>
        <lb facs="#l1" n="1"/>Au commencement était le verbe
        <lb facs="#l2" n="2"/>et le verbe était auprès de Dieu.
      </p>
    </body>
  </text>
```

```
</TEI>
```

À retenir : le `#` devant l'identifiant est obligatoire dans `facs="#l1"`, car c'est une référence interne au document.

20.3 Régularisation des graphies

Les textes anciens contiennent des graphies variables, des abréviations ou des erreurs. La TEI permet de conserver la forme originale **et** de proposer une forme normalisée grâce à `<choice>`.

Balise	Usage
`<orig>` / `<reg>`	graphie originale / graphie régularisée
`<abbr>` / `<expan>`	abréviation / développement
`<sic>` / `<corr>`	erreur présumée / correction

```
<p>
  <!-- Variante graphique -->
  Il estoit <choice>
    <orig>grãd</orig>
    <reg>grand</reg>
  </choice> seigneur.

  <!-- Abréviation -->
  <choice>
    <abbr>Mr</abbr>
    <expan>Monsieur</expan>
  </choice> de La Fontaine

  <!-- Correction d'une faute -->
  Il <choice>
    <sic>mangea</sic>
    <corr>mangeait</corr>
  </choice> tranquillement.
</p>
```

On peut ensuite produire, par une transformation XSLT, une édition diplomatique (on affiche `<orig>`) ou une édition normalisée (on affiche `<reg>`) à partir du même fichier source.

20.4 Utilisation des entités pour les caractères spéciaux

Certains caractères ne peuvent pas être écrits et visualisés tels quels dans le contenu. On les remplace par des **entités**.

20.4.1 Références numériques

Tout caractère Unicode peut être désigné par son code, en décimal (`&#...;`) ou en hexadécimal (`&#x...;`).

```
<p>Le symbole de l'euro : &#8364; ou &#x20AC;</p>
<p>Une lettre médiévale : &#x017F; (s long ſ)</p>
```

Si le fichier est encodé en **UTF-8** (recommandé), on peut écrire directement é, œ, □, ſ. Seuls `<` et `&` restent obligatoirement à échapper.

20.4.2 Entités personnalisées (DTD)

On peut définir ses propres entités dans le prologue du document :

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE texte [
  <!ENTITY etc "et cetera">
  <!ENTITY s-long "&#x017F;">
]>
<texte>
  <p>Des pommes, des poires, &etc;</p>
  <p>Le &s-long;iecle</p>
</texte>
```

20.5 Caractères non standard en TEI

Pour les glyphes absents d'Unicode (ligatures rares, signes d'abréviation), la TEI propose `<charDecl>` et `<g>` :

```
<teiHeader>
  <encodingDesc>
    <charDecl>
      <glyph xml:id="et-tironien">
        <desc>Note tironienne pour « et »</desc>
      </glyph>
    </charDecl>
  </encodingDesc>
</teiHeader>

<p>pain <g ref="#et-tironien">□</g> vin</p>
```

20.6 Lacune, ajouts, description des mains

✻ `<gap>` ou `<unclear>` : pour un passage ne pouvant pas être restitué pour des raisons matérielles

```
<gap reason="illegible" agent="ink-blot"/>
<unclear> passage en partie illisible

<unclear agent="ink-blot" cert="low" resp="#EC">bas</unclear>
```

✻ `<supplied>` : pour restituer un passage manquant

```
<supplied reason="hole" source="#autreEd">les</supplied>
```

20.7 Ajouts et surplus

`<add>` pour le texte ajouté et `<del>` pour le texte raturé.

```
<add place="above">nous</add>
<del> texte supprimé</del>

<del rend="overstrike">claustra</del>
```

20.8 La description des mains

`<@hand>` dans le corps du texte

`<@handDesc>` et ses sous-éléments dans le `<teiHeader>`

```
<handDesc>xml
  <handNote xml:id="c2Hand1" scope="major">à l'encre noire</handNote>
  <handNote xml:id="c2Hand2" scope="minor">au crayon</handNote>
</handDesc>
```

`<handNote>` est répétable et peut contenir une localisation avec `@locus`.

```
<p>Du texte <add hand="#c2Hand2">ajout</add> etc.</p>
```

21 Quelques informations sur la Séquence (ou Cantilène) de sainte Eulalie

La *Séquence de sainte Eulalie* est l'un des plus anciens textes littéraires en langue romane (ancien français naissant). Composée vers **881-882**, elle est conservée dans un unique manuscrit, le **manuscrit 150 de la bibliothèque municipale de Valenciennes**.

Ce poème raconte le martyre d'Eulalie, une jeune chrétienne de Barcelone (début du IVe siècle) qui refuse d'abjurer sa foi malgré les pressions de l'empereur païen Maximien. Spoiler ça finit mal pour elle.

22 Bibliographie et références

TEI Consortium, « History », tei-c.org : https://tei-c.org/about/history/

Michael Sperberg-McQueen, « The Text Encoding Initiative : Its History, Goals, and Future Development », Computers and the Humanities, 1995 (texte disponible : https://www.cs.vassar.edu/~ide/papers/teiHistory.pdf)

American Historical Association (AHA), « The Text Encoding Initiative » : https://www.historians.org/perspectives-article/the-text-encoding-initiative/

« The Text Encoding Initiative Begins », History of Information : https://www.historyofinformation.com/detail.php?id=5007

Article « Text Encoding Initiative », Wikipédia (français) : https://fr.wikipedia.org/wiki/Text_Encoding_Initiative

Elli Mylonas, Allen Renear, « The Text Encoding Initiative at 10 : Not Just An Interchange Format Anymore — but a New Research Community », Computers and the Humanities 33, 1999.

BERTRAND, Lauranne, GUILLOT, Céline, HEIDEN, Serge et LAVRENTIEV, Alexei, rev. BURNARD, Lou et FEKETE, Jean-Daniel, *Manuel d'encodage XML-TEI des textes de la Base de Français Médiéval*, 2009, (En ligne : http://bfm.ens-lyon.fr/IMG/pdf/Manuel_Encodage_TEI.pdf)

BOURGAIN, Pascale et VIELLIARD, Françoise, *Conseils pour l'édition des textes médiévaux. Fascicule III, Textes littéraires*, Paris, France, Comité des travaux historiques et scientifiques : École nationale des chartes, 2018, 254 p., (« Orientations et méthodes », 32)

BUREAU, Bruno, « Quelques réflexions sur la notion de littérarité à partir de l'édition numérique de commentateurs anciens », Interférences. Ars scribendi, janvier 2012, (En ligne : http://journals.openedition.org/interferences/186)

BURNARD, Lou et BURGHART, Marjorie, Qu'est-ce que la *Text Encoding Initiative* ?, 2015 (En ligne : http://books.openedition.org/oep/1237).

VIELLIARD, Françoise et GUYOTJEANNIN, Olivier, *Conseils pour l'édition des textes médiévaux. Fascicule I, Conseils généraux*, Paris, Comité des travaux historiques et scientifiques : École nationale des chartes, 2001.

HAWKINS, Kevin S., Introduction to the TEI Header